

1 背景

随着各类大模型层出不穷，为探究模型的多方面性能，对比不同模型间的差异，大模型的测评也愈加受关注。为了更好的还原应用场景，测评数据集的质量与数量至关重要。人工构建数据集的质量虽然有很高的保障，但人力与时间成本过高，且难以达到足够的体量支撑大模型的测评，因此如何自动的生成可用于大模型测评的数据集亟待解决。本项目借助大模型和 Dify 工作流实现了大模型评测数据集的构建与校验流程的自动化，大大降低了人工构建测评数据集的成本，并且通过校验流程对数据集质量进行了优化。

测评数据集的构建流程包括生成和校验。值得注意的是：生成数据集需要在收集足够的文本材料的基础上展开，为了提高数据集的质量，使其足够覆盖一个学科或领域的各个维度，从而对大模型进行全面的测评，需要首先明确题目生成的材料来源构成，并收集足够的材料，然后再进行数据集的构建。数据源的质量对生成的数据集质量至关重要。



自动化数据集构建需要 Dify^[1]工作环境和 Python^[2]的运行环境，而数据集的评测则需要 Opencompass^[3]评测项目的运行环境，需首先对该部分环境进行配置。此外，Dify 工作流中的大模型使用需要申请对应模型的 API key 进行授权。

目前本项目生成的数据集主要针对的是大模型的学科和知识能力测评，若对大模型的其他能力的有测评数据集的生成需求，则可以根据实际需要修改工作流中大模型节点的提示词。

2 大模型数据集

2.1 公开数据集介绍

对大模型能力及其不足之处形成更深入的认识和理解，预知并防范大模型带

来的安全挑战和风险，需要针对大模型开展全方位的评测，以引导大模型朝着更健康和更安全的方向发展，让大模型的发展成果惠及全人类。如图，天津大学自然语言处理实验室的大模型评测的综述对大模型测评分类及公开数据集进行了总结^[4]。

此外，Opencompass 大模型测评平台上针对大模型的学科、语言、知识、理解、推理、长文本、创作、代码、智能体、数学等能力，截至 2024 年 8 月 8 日共收集了 58 个测评数据集^[5]。例如金融领域由蚂蚁集团和上海财经大学联合发布的金融数据集 Fin-Eva^[6]，以及东方财富和上海人工智能实验室发布的开源金融评测数据集 OpenFinData^[7]。

评测能力	数据集
学科	C-Eval、MMLU、CMMLU、ARC-c、GAOKAO-Bench、ARC-e
语言	CHID、WiC、Flores、AFQMC、WSC
知识	Fin-Eva、TriviaQA、NQ、CommonSenseQA、BoolQ、TyDiQA、OpenFinData
理解	OpenbookQA、C3、LCSTS、CSL、RACE(High)、XSum、LAMBADA、RACE(Middle)、EPRSTMT
推理	BBH、HellaSwag、SIQA、PIQA、CMNLI、DROP、OCNLI、COPA、RTE、MR-Ben-Meta-Reasoning-Benchmark、ReCoRD、AX-b、AX-g
长文本	LongBench、L-Eval、LV-Eval
创作	CreationBench
代码	HumanEval、MBPP、HumanEval-X、DS-1000
智能体	T-Eval
数学	MATH、GSM8K、T-Eval
其他	Flames、SecBench、OCRBench、ChemBench、CriticBench、CS-Bench




Figure 2: An overview of studies on knowledge and capability evaluation for LLMs.

2.2 行业数据集构造材料

2.2.1 材料来源及题数拟定占比

数据来源	时效性要求	数量占比
专业书籍（供应链金融、供应链管理、金融基础、风险管理）	近 10 年	30%

行业研究报告	近 2 年	30%
官方公众号、网站	近 1 年	30%
政策	近 1 年	10%

2.2.2.材料来源详情

材料来源包括专业书、行业报告、政策公告、专业公众号和网站等，详细来源略。

2.3 行业数据集构造流程

手动生成问答数据是通过直接与大模型对话交互过程中限制提示词并上传出题材料进行的，支持的文件格式包括 docx、pdf、txt、jpg 等。通过 dify workflow 生成是通过调用工作流传入出题文本材料进行的，支持的格式仅为文本，包括可以以字符串类型输入的 url 链接。

1.手动生成

批量生成：针对每次上传的文件可以输出规定数量的题目，但需要分批次返回，每次返回的题目数量有限制，大约为 20 道。

支持文件类型：docx、pdf、txt 等。

优点：

- 对于图文表格较多的出题材料友好，可以更多地保留图表信息。

缺点：

- 每次需重新输入提示词并针对返回结果调试，对于 AI 返回的结果还需手动进行汇总整理；
- 不能读取网页链接。

2.Dify 工作流

批量生成：每条工作流内输出题目有限制，但通过 Python 进行 Dify 的循环调用可以批量生产。

支持文件类型：docx、pdf、excel、txt 等，但均需通过 Python 读取转换为文本后输入 workflow。

优点：

- 只要完成出题材料的切分即可进行批量生成，人工成本低。
- 可以读取网站内容。

缺点：


- 需要对文档进行切分预处理，会丢失文档中的图表信息。
- 运行需配置 Python 环境。

构建供应链金融领域数据集需要搜集大量专业文本，其内容需要具备专业性强、时效性高、多样性广等特点。因此选择专业书籍、行业报告、网页链接、相关政策作为出题材料来源。其中行业报告文件中多包含大量的图片和表格，选择通过手动生成的方式效果更佳，而对于书籍、政策等以文本为主的来源则可以在进行切分预处理后，通过 dify workflow 批量生成。

2.3.1 手动生成流程

2.3.1.1 概览

直接通过 AI 对话的交互过程生成 QA 数据，通过结构化提示词，可以对大模型出题的题型、数量、格式等进行限制。



2.3.1.2 模型及提示词

1. 模型选择

【ChatGPT-4o】

（1）**优势**：相比其他大模型如 kimi 生成题目质量更高，回答忠于上传文本，答案歧义更小，问题分布更均匀，输出更稳定；

（2）**不足**：大模型输出文本长度有限，需要多次处理；生成数量偶尔不准确，需要人工校验。

2. 提示词

结构化提示词对稳定生成高质量题目起了关键作用，示例如下：

（1）生成问答题提示词

- **Role**: 供应链金融领域专家出题人
- **Background**: 您需要一个能够理解供应链金融领域专业文本并根据这些文本生成高

质量问答对的出题人，以评估和选择最适合该领域的大模型。

- **Profile:** 这个角色是一位在供应链金融领域拥有深厚知识的专家，具备文本分析、问题生成和答案验证的能力。

- **Skills:** 供应链金融知识、文本分析、问题生成、答案验证。

- **Goals:** 设计一个流程，能够从专业文本中提取关键信息，生成高质量的问答对。

- **Constraints:** 确保生成的问题和答案准确、相关，并且覆盖上传文本的核心内容，避免针对同一句话重复生成问题和答案。

- **OutputFormat:** 问题和答案对的列表，包括问题、答案和相关文本引用。

- **Workflow:**

1. 阅读并分析上传的供应链金融领域文本。
2. 提取文本核心内容，如关键概念、术语和实践，生成相关问题。
3. 根据文本内容，为每个问题生成准确、详细的答案。
4. 验证问题和答案的准确性和相关性。
5. 提供引用原文中的相关片段。
6. 将问题、选项和正确答案、引用原文配对，形成问答题数据集。

- **Examples:** **Question:** 供应链金融中的应收账款融资是什么？ **Answer:** 应收账款融资是一种融资方式，供应商将其应收账款出售或质押给金融机构，以换取即时资金。 **Context:** 应收账款融资是供应链金融中的一种融资方式，供应商将其应收账款出售或质押给金融机构，以换取即时资金。这种方式允许供应商通过将未来的应收款项作为担保来获得当前所需的资金，从而改善现金流状况。

- **Initialization:** 欢迎使用供应链金融领域专家出题人服务。请上传您希望分析的文本，我将为您生成专业的问答对数据集。

(2) 生成单选题提示词

- **Role:** 供应链金融领域专家出题人

- **Background:** 用户需要一个能够理解供应链金融领域专业文本，并根据这些文本生成单选题数据集的出题人，以评估和选择最适合该领域的大模型。

- **Profile:** 这个角色是一位在供应链金融领域拥有深厚知识的专家，具备文本分析、问题生成、选项设计和答案验证的能力。

- **Skills:** 供应链金融知识、文本分析、问题生成、选项设计、答案验证、模型评估。

- **Goals:** 设计一个流程，能够从专业文本中提取关键信息，生成高质量的单选题。
- **Constraints:** 确保生成的问题和选项准确、相关，并且覆盖上传文本的核心内容，避免针对同一句话重复生成问题和答案。

- **OutputFormat:** 单选题数据集，包括问题、选项和正确答案、相关文本引用。

- **Workflow:**

1. 阅读并分析上传的供应链金融领域文本。
2. 提取关键概念、术语和实践，生成相关问题。
3. 为每个问题设计多个选项，包括一个正确答案和几个干扰项。
4. 验证问题和选项的准确性和相关性。
5. 提供引用原文中的相关片段
6. 将问题、选项和正确答案、引用原文配对，形成单选题数据集。

- **Examples:** **Question:** 供应链金融中常见的融资模式是什么？ **Options:** A. 应收账款融资 B. 库存融资 C. 预付款融资 D. 所有以上 **Answer:** D

Context: 供应链金融中常见的融资模式包括应收账款融资、存货融资和预付账款融资。应收账款融资允许供应商将其应收账款出售或质押给金融机构以换取即时资金。存货融资涉及使用存货作为担保来获取贷款。预付账款融资则是买方获得资金以预付给供应商，以期获得价格优惠或确保货物供应。

- **Initialization:** 欢迎使用供应链金融领域专家出题人服务。请上传您希望分析的文本，我将为您生成专业的单选题数据集。

2.3.1.3 QA 生成

2024供应链金融蓝皮书.docx
PDF

请生成10个示例问答对，以表格形式输出

从提供的文档中提取和生成了以下十个示例问答对。它们涵盖了供应链金融的定义、商业模式、发展趋势、中小微企业融资痛点等方面。

问题	答案	相关文本引用
供应链金融的定义是什么？	供应链金融是一套融资和支付解决方案，旨在通过利用供应链大型企业（通常称为核心企业）的信用来优化支付周期并提高供应商和买方的营运资金效率。供应链资产包括多种类型，如应收账款、预付款项及存货等。	供应链金融是一套融资和支付解决方案，旨在通过利用供应链大型企业（通常称为核心企业*）的信用来优化支付周期并提高供应商和买方的营运资金效率。供应链资产包括多种类型，如应收账款、预付款项及存货等。[1]
什么是供应链金融的核心企业？	核心企业是供应链中的主导参与者，通常是指信用状况良好且对产业链上的其他企业有重要影响的典型大型企业。	核心企业指供应链中的主导参与者，通常是指信用状况良好且对产业链上的其他企业有重要影响的典型大型企业。[1]
供应链金融的商业模式有哪些？	供应链金融的商业模式包括应收账款融资、库存融资和预付款融资等，通过整合核心企业及其供应商之间的各种贸易活动产生的信息流、物流和资金流，使金融机构能够有效地管理风险，并提供更灵活的融资选择。	供应链金融商业模式包括应收账款融资、库存融资和预付款融资，通过整合核心企业及其供应商之间的各种贸易活动产生的信息流、物流和资金流，使金融机构能够有效地管理风险。[1]
中小微企业在融资过程中面临哪些痛点？	中小微企业在融资过程中面临融资渠道单一、银行贷款审批放款难以及融资成本高企等痛点。	中小微企业在融资过程中面临融资渠道单一、银行贷款审批放款难以及融资成本高企等痛点。[1]
什么是应收账款融资？	应收账款融资是一种融资方式，供应商将其应收账款出售或质押给金融机构，以换取即时资金。	应收账款融资是一种融资方式，供应商将其应收账款出售或质押给金融机构，以换取即时资金。[1]



供应链金融交易.docx

文档

请根据附件提供的新文本生成10道单选题数据集



根据您提供的文本生成了以下10道单选题数据集：

问题	选项A	选项B	选项C	选项D	答案	上下文引用
什么是仓单质押的主要形式之一？	静态质押	动态质押	担保质押	信用质押	A	仓单质押是指借方企业以物流企业开出的仓单作为质押物向银行申请贷款的信贷业务，是物流企业参与下的权利质押业务。
保兑仓融资模式主要解决了什么问题？	库存积压	采购阶段的资金短缺	销售环节的滞销	物流配送的延迟	B	保兑仓融资模式的提出主要是针对商品采购阶段的资金短缺问题。
反向保理的主要特点是什么？	对买家进行风险评估	对供应商进行信用评估	基于库存质押	依靠出口信用保险	A	反向保理的根本区别在于：保理商是对作为供应链焦点企业的买家进行风险评估，而不是对供应商进行信用评估。
预付款融资的担保基础是什么？	客户对供应商的提货权	客户的信用评级	库存商品的价值	银行的担保协议	A	预付款融资的担保基础是预付款项下客户对供应商的提货权，或提货权实现后通过发货、运输等环节形成的在途存货和库存存货。
战略关系融资的独特之处在于什么？	融资过程中不涉及银行参与	融资基于双方的长期合作关系	融资需要大量的抵质押物	融资主要用于短期项目	B	战略关系融资的独特之处在于，融资并不以某个单独交易为依据，而是以双方的长期合作关系为基础，甚至不涉及抵质押物品。



第10章.docx

文档

请根据新上传的附件文本生成10个问答对数据



根据最新上传的附件文本生成以下10个供应链金融领域的问答对数据集：

问题	答案	引用
供应链风险的主要类型有哪些？	供应链风险主要包括内部供应链风险和外部供应链风险，以及环境因素、行业因素、组织因素、特定问题因素和与决策者相关的因素。	“供应链风险的类型 关于供应链风险的形态，很多研究有不同的划分，诸如有的将供应链风险分为内部供应链风险和外部供应链风险（Jüttner 2005），有的将风险按照发生的层级分为环境因素、行业因素、组织因素、特定问题因素以及与决策者相关的因素（Rao & Goldsby 2009）。” ^[1]
什么是供应链中断？	供应链中断是指由诸如破产、自然灾害和恐怖袭击等事件引发的风险，这些事件会严重威胁到企业的正常商业运作。	“供应链中断（supply chain disruptions）在供应链风险研究中出现频率最高。Tang（2006）将供应链风险划分为中断风险（disruption risk）和营运风险（operational risk）。中断风险是由诸如破产、自然灾害和恐怖袭击等事件引发的风险。” ^[1]
如何区分供应链风险和供应链中断？	供应链风险是一个广义的概念，包括各种不确定性带来的消极结果，而供应链中断是供应链风险的一种具体表现形式。	“供应链风险与供应链中断是两个不同的概念。供应链中断是供应链风险具体化的一些事件。” ^[1]
供应链脆弱性和供应链风险有何关系？	供应链脆弱性是指供应链容易受到干扰和中断的特性，通常与供应链风险互换使用，反映的是供应链对风险的敏感度。	“供应链脆弱性和供应链风险经常被作为两个互换使用的概念。” ^[1]
什么是供应链弹性？	供应链弹性是指供应链为了应对不可预知的事件和中断并保持连续性水平，对供应链结构	“供应链弹性是指供应链为了应对不可预知的事件、中断以及完成恢↓保持连续性水平，对供应链结构和职能进行控制的一种适应性能力。” ^[1]

请根据附件提供的新文本生成10道单选题数据集

根据您提供的文本生成了以下10道单选题数据集：

问题	选项A	选项B	选项C	选项D	答案	上下文引用
大数据在数据管理中存在的三个维度的挑战包括以下哪一项？	数据量大、数据类型繁多、数据增长快	数据质量差、数据存储难、数据处理慢	数据准确性低、数据完整性差、数据时效性差	数据获取难、数据分析难、数据利用难	A	Laney（2001）指出，在数据管理中，存在三个维度的挑战，即数据量大（volume）、数据类型繁多（variety）以及数据增长快（velocity）。
大数据的3V构架中不包括以下哪一项？	数据量大	数据价值高	数据类型繁多	数据增长快	B	McAfee等（2012）也指出，“大数据”和以往的分析学相比，存在上述的3V区别。
大数据具有以下哪项特性？	准确性、完整性、一致性、时效性	海量、多样性、速度、价值高	可用性、可靠性、安全性、经济性	可访问性、可扩展性、可管理性、可分析性	B	总之，如今海量（volume）、多种类型（variety）、速度快（velocity）、价值高（value）的大数据成为了企业增进绩效、推动业务创新的重要因素。
供应链中的大数据类型不包括以下哪一项？	结构数据	非结构数据	传感器数据	地理数据	D	供应链中的大数据主要包括以下四种类型：结构数据、非结构数据、传感器数据和新类型数据。

2.3.2 dify 工作流生成

2.3.2.1 概览

1.工作流文件

行业 QA 数据集包含主观题和客观题，其中客观题分为单项选择题和判断题。三种题型的分别构建工作流，且客观题还需要通过校验工作流进行题目筛选。



上述五个工作流，均导出为 Yaml 源文件，可通过“导入 DSL 文件”功能导入新的 Dify 工作室。



2.工作流类型

在创建空白应用时候均选择聊天助手的方式创建工作流，且仅通过系统变量进行输入输出，未添加新的变量。




2.3.2.2 QA 生成流程

由于生成题目的材料来源分为文本类型和网页链接两种类型，前者可以直接用于生成题目，而后者需要在提取网页页面内容后再作为题目生成的文本来源。因此首先通过“问题分类器”对输入工作流的数据源进行识别分类，再对统一转化为文本材料进行“变量聚合”以输入大模型生成问答数据。由文本转为问题的基本流程为：

- ①大模型生成规定数量的问答题目；
- ②将结构化的问答数据输出。

综上，问答数据的生成流程可抽象为以下的统一流程，输入数据类型为字符

串，输出类型为 json 格式的字符串，不同题型间的区别在于题目生成和格式调整时大模型的提示词。



对相同节点进行统一描述：

【问题分类节点】

该节点通过大模型进行问题分类，对输入工作流的内容进行识别，若为文本即可直接传入题目生成的大模型节点，若为网页链接则需首先提取网页内容。



1.单选题生成



【生成题目提示词】

通过提示词对题目生成节点的大模型功能及输出进行限制。由于 workflow 中的节点输入长度存在限制，因此目前设置为运行一次 workflow 生成 10 道单选题，该设置可以根据实际需要在 dify 工作流的 LLM 节点提示词中进行修改，并且基于以网站为出题来源时网站内容含量的局限，此时建议减少单次出题数量，避免出错或影响生成题目的质量。

```
SYSTEM 538 Jinja (x) [ ] ?
- Role: 单选题专家出题人
- Background: 用户需要一个能够理解所给文本内容，并根据这些文本生成10道单选题，并输出json格式的出题人。
- Profile: 这个角色是一位经验丰富的单选题出题专家，具备文本分析、问题生成、选项设计、格式化输出的能力。
- Skills: 文本分析、问题生成、选项设计、格式化输出。
- Goals: 设计一个流程，能够从专业文本中提取关键信息，生成10道高质量的单选题，并以json格式输出。
- Constrains: 确保生成的问题和选项准确、相关，并且覆盖上传文本的核心内容，避免针对同一句话重复生成问题和答案，不要出现以上全部、所有以上、某项和某项、无法确定这类造成选项之间包含关系的选项。
- OutputFormat: 单选题，包括问题、ABCD四个选项和正确答案
- Workflow:
1. 阅读并分析上传的文本。
2. 提取关键概念、术语和实践，生成相关问题。
3. 为每个问题设计4个选项，包括一个正确答案和3个干扰项，不要出现选项之间的包含关系。
4. 验证问题和选项的准确性和相关性。
5. 将问题、选项和正确答案配对，形成单选题。
7. 一共生成10道题目,并按要求输出json。
```

```
USER 128 Jinja (x) [ ] ?
供应链金融中常见的融资模式包括应收账款融资、存货融资和预付账款融资。应收账款融资允许供应商将其应收账款出售或质押给金融机构以换取即时资金。存货融资涉及使用存货作为担保来获取贷款。预付账款融资则是买方获得资金以预付给供应商，以期获得价格优惠或确保货物供应。

ASSISTANT 296 Jinja (x) [ ] ?
{
  "question": "供应链金融中常见的融资模式是什么",
  "options": {
    "A": "应收账款融资",
    "B": "库存融资",
    "C": "预付款融资",
    "D": "所有以上"
  },
  "answer": "D"
},
{
  "question": "应收账款融资的融资模式的流程是怎样的？",
  "options": {
    "A": "供应商将其应收账款出售或质押给金融机构以换取即时资金",
    "B": "使用存货作为担保来获取贷款",
    "C": "买方获得资金以预付给供应商，以期获得价格优惠或确保货物供应",
    "D": "不确定"
  }
}
```

【输出数据案例】

```
Json
1 [
2   {
3     "question": "物流领域
4     中的供应链金融可以看作什么?",
5     "options": {
6       "A": "一种集物流运
7       作、商业运作和金融管理为一体的管理行为和
8       过程",
9       "B": "一种仅涉及现
10      代物流服务的业务",
11      "C": "一种仅涉及金
12      融服务的业务",
13      "D": "一种仅涉及第
14      三方物流服务的业务"
15    },
16    "answer": "A"
17  },
18  {
19    "question": "物流金融
20    的实质是什么?",
21    "options": {
22      "A": "一种短期性融
23      资行为",
24      "B": "一种长期性投
25      资行为",
26      "C": "一种库存管理
27      行为",
28      "D": "一种企业理财
29      行为"
30    },
31    "answer": "A"
32  }
33 ]
```

2.判断题生成



【生成题目提示词】

判断题的工作流目前设置为每次运行工作流生成五题,可以根据实际素材和需要进行修改。

SYSTEM ⓘ

486 Jinja (x) 📄 ↻

- Role: 判断题出题专家

- Background: 用户需要根据特定的材料生成判断题，这些题目专注于考察概念、结论等命题以及其他信息的考察，不涉及数据和时效性信息。

- Profile: 您是一位专业的判断题出题专家，擅长从材料中提炼关键概念和信息，用于出5道高质量判断题输出为json格式。

- Skills: 材料分析、概念提取、问题构建、原文追溯、格式化输出。

- Goals: 创建5道判断题，每题都包含题干、“Y”或“N”答案选项。

- Constrains: 题目应避免涉及数据和时效性信息，专注于概念和结论的理解，确保出题来源围绕材料，不要只出答案是Y的判断题，要有对有错，不能改变出题数量必须出5题，最后按照要求输出json。

- OutputFormat: 每个问题应包括题干、“Y”或“N”答案选项。

- Workflow:

1. 阅读并分析给定材料。

2. 识别材料中的关键概念和结论。

3. 根据这些概念和结论构建判断题。

4. 为每个问题提供“Y”或“N”答案选项。

5. 一共生成5道高质量简答题，并输出json。

USER ⓘ

84 Jinja (x) 📄 ↻

与传统金融相比，数字人民币具有支付即结算、依法可追溯、高安全性等特性，通过加载智能合约，具备‘全周期流向透明可查’‘支持24小时大额放款’‘资金按合约自动执行’等优势。

ASSISTANT ⓘ

54 Jinja (x) 📄 ↻

{
 "question": "数字人民币和传统金融都是依法可追溯的。",
 "answer": "N"
}

【输出数据案例】

Json 📄

```
1  [  
2    {  
3      "question": "物流领域的  
供应链金融起源于第三方物流的业务活  
动。",  
4      "answer": "Y"  
5    },  
6    {  
7      "question": "物流金融的  
实质是将库存视为现有资产并以此获得  
融资的行为过程。",  
8      "answer": "Y"  
9    },  
10   {  
11     "question": "物流金融的  
发展与第三方物流的业务复杂性无  
关。",  
12     "answer": "N"  
13   },  
14   {  
15     "question": "在物流金融  
中，金融机构需要直接参与供应链物流  
的运行。",  
16     "answer": "N"  
17   },  
18   {  
19     "question": "物流金融的  
运用性受到限制主要是因为金融机构难  
以确定质押品和担保品的价值和稳定  
性。",  
20     "answer": "Y"  
21   }  
22 ]
```

简答题的工作流目前设置为每次运行工作流生成五题，同样可以根据实际素材和需要进行修改。

ASSISTANT ◇ 345 Jinja 0 [x] 0

```
{
  "question": "解释在供应链金融中数据与金融协作的重要性。",
  "answer": "在供应链金融中，数据与金融协作非常重要，主要体现在以下几个方面：数据的真实性和准确性能够有效降低金融风险；银保协作在信用证业务中发挥关键作用，提升中小企业融资的可行性；数据驱动的金融产品，如供应链票据和保融+融资类业务，在提升融资效率和透明度方面具有显著优势；数据的广泛应用有助于提高金融机构对中小企业的信心，促进经济复苏。",
  "original_text": "与其他业务相比，供应链票据相关业务、保融+融资类业务和信用证类业务未来仍将会受到较大关注。与其他业务相比，上述三个业务更依赖数据的作用和银保协作，体现出数据和金融协作在中小企业融资服务中将发挥更加不可替代的作用。" }
```

```
Json
1  [
2      {
3          "question": "物流领域的供应链金融是如何提升第三方物流企业的业务能力和效益的?",
4          "answer": "物流领域的供应链金融通过结合物流与金融,不仅提升了第三方物流企业的业务能力及效益,还能为企业融资并提升资本运用的效率。",
5          "original_text": "物流领域的供应链金融是物流与金融相结合的复合业务概念,它不仅能提升第三方物流企业的业务能力及效益,还能为企业融资并提升资本运用的效率。"
6      },
7      {
8          "question": "物流金融在金融业务中有哪些功能?",
9          "answer": "物流金融的功能包括帮助金融机构扩大贷款规模、降低信贷风险,协助金融机构处置部分不良资产、有效管理客户,以及提升质押物评估、企业理财等顾问服务项目。",
10         "original_text": "物流金融的功能是帮助金融机构扩大贷款规模、降低信贷风险,在业务服务扩展上能协助金融机构处置部分不良资产、有效管理客户,提升质押物评估、企业理财等顾问服务项目。"
11     },
12 ]
```


2.3.2.3 QA 校验流程

大模型在生成题目的过程中,存在一部分针对强时效性的信息和数据生成的题目,此类题目需要结合出题材料才能完成,不具备考察大模型在特定领域的知识能力的作用,因此可以通过大模型做题进行筛选,若与标准答案不同,则舍去该题。上述信息类的题目基本可以通过校验过程筛去。

校验过程即为设置做题节点大模型的提示词,使其根据输入的题目进行回答,批量做题后汇总做题结果,与原答案进行比对,仅保留答案相同的题目。

校验过程仅针对数据集中的客观题,即单选题和判断题。

1.单选题校验



【做题提示词】

通过提示词要求做题节点的大模型根据输入的单项选择题做出选择，并生成解析，对其选择解释原因。

SYSTEM 345 Jinja (x) [icon]

- Role: 做题机器人

- Background: 用户需要一个能够自动完成单选题并提供答案解析的AI助手。

- Profile: 您是一个专业的做题机器人，具备快速准确地完成单选题并提供详细解析的能力。

- Skills: 阅读理解、逻辑推理、知识应用、解析表达。

- Goals: 根据用户输入的单选题，选择正确的选项并提供详细的解析。

- Constrains: 确保答案的准确性，解析的清晰性和逻辑性。

- OutputFormat: 文本回复，包含选择的选项和对应的解析。

- Workflow:

1. 接收用户输入的单选题和选项。
2. 分析题目和选项，确定正确答案。
3. 根据正确答案提供详细的解析。
4. 以文本形式回复用户，包括选择的选项和解析。

USER 45 Jinja (x) [icon]

- Examples:

法国的首都哪里？

A. 伦敦 B. 巴黎 C. 罗马 D. 柏林

ASSISTANT 35 Jinja (x) [icon]

答案：B

解析：巴黎是法国的首都，因为它是法国的政治、经济和文化中心。

USER 37 Jinja (x) [icon]

水的化学式是什么？

A. H2O B. O2 C. CO2 D. CH4

ASSISTANT 41 Jinja (x) [icon]

答案：A

解析：水的化学式是H2O，这表示一个水分子由两个氢原子和一个氧原子组成。

USER 15 Jinja (x) [icon]

开始 / (x) sys.query

【格式规范提示词】

对每道单选题的作答和解析回复包含：“答案”、“解析”，共 2 个字段，此段 workflow 每次运行完成一道单选题题目，输出一个长度为 2 的字符串列表。

SYSTEM 454 Jinja (x) [icon]

- Role: 文本规范化处理专家
- Background: 用户需要将输入的文本中的问题进行规范化处理, 以便于后续的分析、学习和评估。
- Profile: 您是一位专业的文本规范化处理专家, 具备将不同格式的文本问题转换为统一标准化格式的能力。
- Skills: 文本分析、格式化处理、信息提取、逻辑结构化。
- Goals: 将用户输入的文本中的问题规范化为简答题和选择题的统一格式。
- Constrains: 确保格式化后的文本清晰、准确, 并且遵循指定的结构要求。请完全要求修改格式, 不要对 outputformat 中限制的字段名作任何修改。
- OutputFormat:
 - 简答题格式: 答案、解析
- Workflow:
 1. 接收用户输入的文本。
 2. 识别文本中的简答题和选择题。
 3. 对简答题进行格式化处理, 包括题目、答案和原文引用。
 4. 对选择题进行格式化处理, 包括答案、解析。
 5. 确保每个问题都严格遵循上述格式要求。
 6. 输出规范化后的文本。

USER 37 Jinja (x) [icon]

1答案: B
2解析: 巴黎是法国的首都, 因为它是法国的政治、经济和文化中心。

ASSISTANT 35 Jinja (x) [icon]

答案: B
解析: 巴黎是法国的首都, 因为它是法国的政治、经济和文化中心。

USER 39 Jinja (x) [icon]

正确答案: B
回答解析: 巴黎是法国的首都, 因为它是法国的政治、经济和文化中心。

ASSISTANT 35 Jinja (x) [icon]

答案: B
解析: 巴黎是法国的首都, 因为它是法国的政治、经济和文化中心。

USER 14 Jinja (x) [icon]

① 做题 / (x) text

2.判断题校验



【做题提示词】

通过提示词规定做题节点的大模型根据输入的判断题做出正误判断, 正确回复 Y, 错误回复 N, 并生成解析, 对其判断结果进行解释。

SYSTEM 368 Jinja (x) [icon] [icon]

- Role: 做题机器人

- Background: 用户需要一个能够自动完成判断题并提供答案解析的AI助手。

- Profile: 您是一个专业的做题机器人，具备快速准确地完成单选题并提供详细解析的能力。

- Skills: 阅读理解、逻辑推理、知识应用、正误判断、解析表达。

- Goals: 根据用户输入的判断题，做出正误判断并提供详细的解析。

- Constrains: 确保答案的准确性(只能回答Y或者N)，解析的清晰性和逻辑性。

- OutputFormat: 文本回复，包含判断结果（正确的回复Y，错误的回复N）和对应的解析。

- Workflow:

1. 接收用户输入的判断题。
2. 分析题目判断正误，回复Y或N。
3. 根据判断提供详细的解析。
4. 以文本形式回复用户，包括选择的选项和解析。

USER 20 Jinja (x) [icon] [icon]

- Examples:
苹果树是草本植物

ASSISTANT 18 Jinja (x) [icon] [icon]

答案: N
解析: 苹果树应为木本植物。

USER 10 Jinja (x) [icon] [icon]

水的化学式是H₂O

ASSISTANT 41 Jinja (x) [icon] [icon]

答案: Y
解析: 水的化学式是H₂O，这表示一个水分子由两个氢原子和一个氧原子组成。

USER 15 Jinja (x) [icon] [icon]

开始 / (x) sys.query

【格式规范提示词】

对每道单选题的作答和解析回复包含：“答案”、“解析”，共2个字段，此段 workflow 每次运行完成一道单选题题目，输出一个长度为2的字符串列表。

SYSTEM 407 Jinja (x) [icon] [icon]

- Role: 文本规范化处理专家

- Background: 用户需要将输入的文本中的问题进行规范化处理，以便于后续的分析、学习和评估。

- Profile: 您是一位专业的文本规范化处理专家，具备将不同格式的文本问题转换为统一标准化格式的能力。

- Skills: 文本分析、格式化处理、信息提取、逻辑结构化。

- Goals: 将用户输入的文本中的问题规范化为简答题和选择题的统一格式。

- Constrains: 确保格式化后的文本清晰、准确，并且遵循指定的结构要求。请完全要求修改格式，不要对 outputformat 中限制的字段名作任何修改。

- OutputFormat:

- 简答题格式: 答案、解析

- Workflow:

1. 接收用户输入的文本。
2. 对回答文本进行格式化处理，包括答案、解析。
5. 确保每个问题的回答都严格遵循上述格式要求。
6. 输出规范化后的文本。

USER 37 Jinja (x) [icon] [icon]

1答案: N
2解析: 巴黎是法国的首都，因为它是法国的政治、经济和文化中心。

ASSISTANT 35 Jinja (x) [icon] [icon]

答案: N
解析: 巴黎是法国的首都，因为它是法国的政治、经济和文化中心。

USER 39 Jinja (x) [icon] [icon]

正确答案: Y
回答解析: 巴黎是法国的首都，因为它是法国的政治、经济和文化中心。

ASSISTANT 35 Jinja (x) [icon] [icon]

答案: Y
解析: 巴黎是法国的首都，因为它是法国的政治、经济和文化中心。

USER 14 Jinja (x) [icon] [icon]

做题 / (x) text

2.3.2.4 API 调用 workflow 批量生成和校验 QA

1. 通过 API 调用 dify 工作流

在 python 脚本中调用 dify 工作流，需要由基础 url 确定 dify 工作室的环境，以及 API key 确定工作流。

基础 URL

Code

```
http://10.10.10.10:41/v1
```


鉴权

Service API 使用 `API-Key` 进行鉴权。强烈建议开发者把 `API-Key` 放在后端存储，而非分享或者放在客户端存储，以免 `API-Key` 泄露，导致财产损失。所有 API 请求都应在 `Authorization` HTTP Header 中包含您的 `API-Key`，如下所示：

Code

```
Authorization: Bearer {API_KEY}
```

Dify 工作流的 API key 可以由下图流程创建。



以校验时调用 dify 的方法为例：

```
def checkQA(input_text):
    response_text = []
    url = 'your_dify_url' #http://127.0.0.1:5001/v1/chat-messages
    data = {
        "inputs": {},
        "query": input_text,
        "response_mode": "blocking",
        "conversation_id": "",
        "user": "abc-123",
    }
    json_data = json.dumps(data)
    response = requests.post(url,
                             data=json_data,
                             headers={
                                 "Content-Type": "application/json",
                                 'Authorization': f'Bearer your_dify_workflow_apikey'
                             })

    response_text = response.text
    print(response_text)
    return json.loads(response_text)['answer']
```

2. 通过 txt 文本文档批量生成

(1) 通过文件夹地址读取指定文件夹内全部 txt 文档

【获取文档地址】

```
def get_files_absolute_paths(folder_path):

    result = []

    # 确保给定的路径是存在的

    if not os.path.exists(folder_path):

        print(f"The path {folder_path} does not exist.")

        return []

    # 列出给定文件夹中的所有文件（不包括子文件夹）

    for file in os.listdir(folder_path):

        if os.path.isfile(os.path.join(folder_path, file)):

            # 构造文件的绝对路径

            file_path = os.path.abspath(os.path.join(folder_path, file))

            result.append(file_path)

    # 输出文件的绝对路径

    return result
```

【读取文档】

```
def read_txt_file(file_path):  
    with open(file_path, 'r', encoding='utf-8', errors='ignore') as file:  
        content = file.read()  
    return content
```

(2) 调用 dify 工作流出题

```
def get_llm_response(input_text):                #通过 txt 出题  
    url = 'your_dify_url'  
    data = {  
        "inputs": {},  
        "query": input_text,  
        "response_mode": "blocking",  
        "conversation_id": "",  
        "user": "abc-123",  
    }  
    json_data = json.dumps(data)  
    response = requests.post(url,  
                             data=json_data,  
                             headers={  
                                 "Content-Type": "application/json",  
                                 'Authorization': f'Bearer your_dify_workflow_apikey'  
                             })  
    response_text = response.text  
    return json.loads(response_text)['answer']
```

(3) 处理 workflow 返回数据

```
def cache(array):  
    array_3x3 = array.reshape((3, 3))  
    df = pd.DataFrame(array_3x3)  
    return df
```

(4) 批量生成

```
for file_index, file_path in enumerate(files_path):  
    time.sleep(5) # 暂停 5 秒  
    file_content = read_txt_file(file_path) # 读取文本内容  
    print(file_content)  
    try:  
        llm_response = get_llm_response(file_content) # 调用 workflow 生成题目  
        match = re.search(r'\[.*?\]', llm_response, re.DOTALL)  
        print(match.group(0))  
        data = json.loads(match.group(0))  
        returndf = pd.DataFrame([  
            {  
                "question": item["question"],  
                "A": item["options"]["A"],  
                "B": item["options"]["B"],  
                "C": item["options"]["C"],  
                "D": item["options"]["D"],  
                "answer": item["answer"]  
            }  
            for item in data  
        ])  
        returndf = returndf.assign(url=str(file_path))  
        df = pd.concat([df, returndf], axis=0, ignore_index=True) # 将数据追加到 df  
    except Exception as e:  
        print(f"error: {file_path}, Error: {e}")  
        failed_files.append(file_path) # 将出错的 file_path 添加到列表中  
        error.append(e)
```

3. 通过链接 url 批量生成

(1) 调用 dify 工作流出题

```
def get_llm_response(input_text):          #通过 url 出题

    response_text = []

    url = 'your_dify_url'

    data = {

        "inputs": {},

        "query": input_text,

        "response_mode": "blocking",

        "conversation_id": "",

        "user": "abc-123",

    }

    json_data = json.dumps(data)

    response = requests.post(url,

                              data=json_data,

                              headers={

                                  "Content-Type": "application/json",

                                  'Authorization':f'Bearer your_dify_workflow_apikey'

                              })

    response_text = response.text

    #print(response_text)

    return json.loads(response_text)['answer']
```

(2) 批量生成

```
for i in url_list:

    try:

        #time.sleep(0.5) # 暂停 0.5 秒
```

```

llm_response = get_llm_response(i) # 调用 workflow 生成题目
match = re.search(r'\[.*?\]', llm_response, re.DOTALL)
print(match.group(0))
data=json.loads(match.group(0))
returndf = pd.DataFrame([
    {
        "question": item["question"],
        "A": item["options"]["A"],
        "B": item["options"]["B"],
        "C": item["options"]["C"],
        "D": item["options"]["D"],
        "answer": item["answer"]
    }
    for item in data
])
returndf = returndf.assign(url=str(i))
df = pd.concat([df, returndf], axis=0, ignore_index=True) # 将数据追加到 df
except Exception as e:
    print(f"error: {i}, Error: {e}")
    failed_url.append(i) # 将出错的 file_path 添加到列表中
    error.append(e)

```

4. 批量校验

(1) 调用 dify 工作流做题

```

def checkQA(input_text): # 题目输入

    response_text = []

    url = 'your_dify_url'

    data = {

        "inputs": {},

        "query": input_text,

        "response_mode": "blocking",

        "conversation_id": "",

        "user": "abc-123",

    }

    json_data = json.dumps(data)

```

```

response = requests.post(url,
                          data=json_data,
                          headers={
                              "Content-Type": "application/json",
                              'Authorization': f'Bearer your_dify_workflow_apikey'
                          })

response_text = response.text

print(response_text)

return json.loads(response_text)['answer']

```

（2）处理 workflow 返回数据

```

def cache(array):
    array_1x2 = array.reshape((1, 2))

    df = pd.DataFrame(array_1x2)

    return df

```

（3）批量校验

```

c=['id','来源','Question','A','B','C','D'] #待读取字段
QA_list = pd.read_excel('your_xlsx_name.xlsx')[c]

df = pd.DataFrame()
df_error = pd.DataFrame()
for index, row in QA_list.iterrows():
    try:
        time.sleep(8) # 暂停 8 秒 minimax 多等一会比较稳定

        # 创建一个包含当前行所有数据的字符串

        Qstr = f"Question: {row['Question']}\nA: {row['A']}\nB: {row['B']}\nC: {row['C']}\nD: {row['D']}"

        print(Qstr)

```

```

A = checkQA(Qstr) # 调用工作流生成题目

# 将响应转换成 JSON 对象，然后转换成 NumPy 数组

Alist = json.loads(A)

array = np.array(Alist)

returndf = cache(array) # 假设 cache 函数返回一个 DataFrame

# 将当前行和 returndf 合并

combined_df =

pd.DataFrame([row]).reset_index(drop=True).join(returndf.reset_index(drop=True))

# 将数据追加到 df

df = pd.concat([df, combined_df], axis=0, ignore_index=True)

except Exception as e:

    df_error = pd.concat([df_error, pd.DataFrame([row])], axis=0,
ignore_index=True)

```

3 实践

由上述流程进行行业知识的问答数据集的生成与校验，使用 Opencompass 平台进行数据集的评测。

3.1 数据集生成结果概况

1.数量

类型	数量
单选	2959
判断	975
简答	1161
合计	5095

2.待测试数据集类型转换

Opencompass 支持用户通过自定义新的数据集进行模型测评，在上述数据集生成流程中产生的数据集均存为 excel 格式，而 opencompass 支持 .jsonl 和 .csv 两种格式的数据集。此次选择.jsonl 格式

使用 python 进行格式转换：

```
import pandas as pd
import json
# 读取 Excel 文件
df = pd.read_excel('TF.xlsx') # 替换为你的文件路径和工作表名

# 将 DataFrame 转换为 JSON 格式
json_data = df.to_json(orient='records',force_ascii=False)
json_data=json.loads(json_data)
# 将数据保存为 JSONL 文件
# 打开文件准备写入
with open('data.jsonl', 'w',encoding='utf-8') as file:
    # 遍历数据列表
    for data in json_data:
        # 将字典转换为 JSON 字符串
        json_str = json.dumps(data,ensure_ascii=False)
        # 写入文件，并添加换行符
        file.write(json_str + '\n')
```

3.待测评数据集

名称	类型
 mcq.jsonl	JSONL 文件
 qa.jsonl	JSONL 文件
 TorF.jsonl	JSONL 文件

3.2 评测模型

参与测评的模型包括 OpenAI 的 gpt-4o，智谱 AI 的 GLM-4、GLM-4V、GLM-4-520，minimax-abab6. 5s-chat、ERNIE-Speed-128K，以及本地部署的模型：qwen1.5-7b、qwen1.5-72b、qwen2-7b、qwen2-72b，internlm2_5-7b-chat，llama3-8b-chinese。

3.3 评测结果

模型	得分
gpt-4o	92.44
glm-4-0520	88.94
glm-4v	82.08
minimax-abab6.5s-chat	93.4
ERNIE-Speed-128K	87.08
llama3-8b-chinese(本地)	77.02
internlm2_5-7b-chat(本地)	82.41
qwen1.5-7b(本地)	83.24
qwen1.5-72b(本地)	89.47
qwen2-7b(本地)	89.14
qwen2-72b(本地)	88.47

4 参考

[1] <https://github.com/langgenius/dify>
[2] <https://www.python.org/>
[3] https://github.com/open-compass/opencompass/blob/main/README_zh-CN.md
[4] <https://doi.org/10.48550/arXiv.2310.19736>
[5] <https://hub.opencompass.org.cn/home>
[6] <https://hub.opencompass.org.cn/dataset-detail/Fin-Eva>
[7] <https://hub.opencompass.org.cn/dataset-detail/OpenFinData>